

Prénom : _____ Nom : _____

Noircissez les cases des affirmations VRAIES. Plusieurs réponses possibles par question. Correction automatique.
IMPORTANT : Remplissez votre nom et prénom sur les DEUX pages (recto et verso).

QCXX RAG : Pipeline et recherche

- ☐ A Le RAG réduit les hallucinations de 70 à 90% par rapport à un LLM seul.
- ☐ B Le pipeline RAG comporte 5 étapes : Chunking, Embedding, Indexation, Retrieval, Generation.
- ☐ C La recherche par embeddings seuls est toujours supérieure à la recherche par mots-clés (BM25).
- ☐ D Le RAG injecte des documents pertinents dans le prompt pour améliorer les réponses du LLM.
- ☐ E Le chunking sémantique est le plus rapide mais le moins précis des stratégies de découpage.

QZSE Cas réels et leçons business

- ☐ A Klarna a d'abord économisé \$40M grâce à l'IA, puis a dû réembaucher des humains.
- ☐ B La leçon principale de Klarna est qu'il faut remplacer les humains le plus rapidement possible pour maximiser les économies.
- ☐ C L'Oréal a construit sa technologie IA (beauty tech) entièrement en interne.
- ☐ D Air Canada a été juridiquement condamnée pour les erreurs commises par son chatbot.
- ☐ E Cursor paie plus à Anthropic (son fournisseur de modèle) qu'il ne génère de chiffre d'affaires.

QBMP Benchmarks et modèles

- ☐ A Aucun modèle ne domine sur l'ensemble des benchmarks indépendants.
- ☐ B Chatbot Arena utilise un système de classement basé sur des notes attribuées par des experts.
- ☐ C Le coût de l'inférence à performance équivalente diminue d'environ 2x par an.
- ☐ D Les modèles open-weights ont un retard sur les benchmarks (comme GPQA) de 5 mois sur les modèles propriétaires.
- ☐ E Le meilleur modèle pour une entreprise dépend de son cas d'usage spécifique, pas du leaderboard.

QBKN Paradigmes d'apprentissage

- ☐ A Le Reinforcement Learning apprend à partir d'exemples étiquetés (Input → Output).
- ☐ B Le Self-Supervised Learning est le paradigme derrière les LLMs et les modèles de diffusion.
- ☐ C L'algorithme kNN (k Nearest Neighbors) est un algorithme d'Unsupervised Learning.
- ☐ D Le clustering est une technique de Supervised Learning.
- ☐ E AlphaGo utilise le Reinforcement Learning pour apprendre à jouer au Go.

QSVG Agents en production

- ☐ A Plus un système agent a d'étapes, plus le risque d'erreur global augmente.
- ☐ B Gartner prédit que 40% des projets agents seront annulés d'ici 2027.
- ☐ C La complexité (frameworks, multi-agents) est recommandée dès le début d'un projet agent.
- ☐ D Le Context Engineering comprend 4 opérations : Write, Select, Compress, Isolate.
- ☐ E Les subagents augmentent le bruit dans le contexte principal de l'agent.

QCYM Définition du Machine Learning (Chip Huyen)

- ☐ A Le Machine Learning nécessite des données existantes ou collectables.
- ☐ B Le ML est particulièrement adapté quand les patterns sont simples et codables manuellement.
- ☐ C Un problème de ML doit être formulable comme un problème de prédiction.
- ☐ D Les patterns appris par un modèle ML n'ont pas besoin de se généraliser à de nouvelles données.
- ☐ E Le K-Means classe un point en fonction de ses K voisins les plus proches.

QEAS Souveraineté et écosystème européen

- ☐ A Le CLOUD Act américain entre en conflit avec le RGPD européen pour l'accès aux données.
- ☐ B Mistral AI atteint 90% de la performance des modèles frontier à 20% du prix.
- ☐ C Hugging Face héberge plus d'un million de modèles d'IA.
- ☐ D L'EU AI Act entre pleinement en vigueur pour les systèmes à haut risque en 2030.
- ☐ E Les États-Unis investissent environ 8 fois plus que la France dans l'IA (investissement privé).

QUHB Infrastructure IA

- ☐ A L'énergie, et non les puces, est le principal goulot d'étranglement qui détermine où l'IA est construite.
- ☐ B ASML (Pays-Bas) est le seul fournisseur mondial de machines de lithographie EUV.
- ☐ C NVIDIA tire l'essentiel de son chiffre d'affaires de ses cartes graphiques gaming.
- ☐ D CUDA crée un effet de verrouillage (lock-in) avec 6 millions de développeurs.
- ☐ E Les modèles open-weights représentent environ 70% de l'utilisation globale des LLMs.

QNBR RAG avancé et décisions

- ☐ A Le RAG est toujours préférable au Fine-tuning, quel que soit le cas d'usage.
- ☐ B Pour un corpus de moins de 500 pages, le Context Stuffing avec Prompt Caching peut remplacer le RAG.
- ☐ C Le RAG permet de citer ses sources, contrairement au Fine-tuning.
- ☐ D Plus de 90% des systèmes RAG complexes performant mieux qu'une baseline simple et bien évaluée.
- ☐ E La combinaison RAG + Fine-tuning peut apporter 10 à 20% de précision supplémentaire par rapport à chacun utilisé seul.

QTKF Métriques de classification

- ☐ A L'Accuracy est généralement la meilleure métrique pour évaluer un classifieur.
- ☐ B La Precision mesure : « parmi mes alertes, combien sont vraies ? ».
- ☐ C Le Recall est prioritaire quand les faux négatifs sont coûteux (ex. : dépistage médical).
- ☐ D Le F1-Score est calculé à partir de la Precision et du Recall.
- ☐ E Un modèle avec 90% de Precision et 10% de Recall a un F1-Score de 50%.

Prénom : _____ Nom : _____

QHAR Méthodologie projet IA

- ☐ A The Bitter Lesson (Sutton) montre que les méthodes générales utilisant le calcul l'emportent toujours sur l'ingénierie manuelle.
- ☐ B Le cycle de vie GenAI est linéaire : Scope → Build → Evaluate → Deploy → terminé.
- ☐ C La baseline (modèle le plus simple possible) doit être établie en premier avant d'itérer.
- ☐ D Un MVP est une version dégradée du produit final.
- ☐ E Règle #1 du ML chez Google : si vous pouvez résoudre le problème sans ML, faites-le d'abord.

QVNL IA Générative vs IA Traditionnelle

- ☐ A L'IA générative représente la majorité de la valeur économique totale créée par l'IA.
- ☐ B Le Machine Learning traditionnel est plus déployé en entreprise que l'IA générative.
- ☐ C L'IA générative sert principalement à la prédiction et l'optimisation.
- ☐ D Le Deep Learning est un sous-ensemble du Machine Learning.
- ☐ E ChatGPT est un exemple d'IA générative.

QKDV Business Models IA

- ☐ A Le modèle de pricing par siège (seat-based) est en croissance dans le SaaS IA.
- ☐ B Le modèle hybride (abonnement + crédits à l'usage) est désormais le plus adopté.
- ☐ C Les wrappers IA (simples interfaces autour d'un LLM) ont un taux de réussite d'environ 85%.
- ☐ D Le Vertical AI SaaS offre un TAM (Total Addressable Market) jusqu'à 10x supérieur au SaaS traditionnel du même secteur.
- ☐ E Le moat le plus durable en IA est le modèle lui-même (sa performance sur les benchmarks).

QTXV Pipeline d'entraînement des LLMs

- ☐ A Le Pretraining apprend le langage à partir de trillions de tokens issus d'internet.
- ☐ B Le RLHF (Reinforcement Learning from Human Feedback) est l'étape qui apprend au modèle à suivre des instructions.
- ☐ C Un Thinking Model (ex. : o3, DeepSeek-R1) est entraîné avec une étape supplémentaire de raisonnement.
- ☐ D Le Fine-tuning coûte aussi cher que le Pretraining d'un modèle.
- ☐ E Le Supervised Instruction Finetuning est la troisième étape d'entraînement d'un LLM.

QTEV Tâches d'IA

- ☐ A La Classification assigne une catégorie discrète à une entrée (ex. : Spam / Non-spam).
- ☐ B La Régression prédit une valeur continue (ex. : prix d'un appartement).
- ☐ C L'Object Detection identifie chaque pixel de l'image par catégorie.
- ☐ D La Segmentation Sémantique sépare les objets individuels et la Segmentation d'Instance colore par catégorie.
- ☐ E Un système de recommandation (Netflix, Spotify) est un cas d'usage typique du Machine Learning traditionnel.

QAAF Sampling et Mixture of Experts

- ☐ A Une température basse (0.1) produit des réponses plus créatives et variées.
- ☐ B Le Mixture of Experts (MoE) active tous ses experts pour chaque token généré.
- ☐ C L'architecture de Mixture of Experts (MoE) est idéale pour réduire le besoin en vRAM d'un modèle.
- ☐ D Le Top-p (nucleus sampling) conserve les tokens dont la probabilité cumulée ne dépasse pas p.
- ☐ E Le MoE offre la performance d'un grand modèle avec la vitesse d'un petit modèle.

QJLW Embeddings

- ☐ A Un embedding transforme du texte en coordonnées dans un espace mathématique.
- ☐ B Il n'est pas possible de comparer à quel point un embedding est similaire à un autre.
- ☐ C Deux textes avec un sens similaire auront des embeddings proches dans l'espace vectoriel.
- ☐ D Les relations sémantiques capturées par les embeddings sont programmées manuellement.
- ☐ E Il existe des embeddings pour différents types de données (text, image, protéines, ...)

QZYU Agents IA : définition et spectre

- ☐ A Un agent IA est un LLM capable de raisonner, planifier et interagir avec son environnement.
- ☐ B Le cycle ReAct (Think → Act → Observe) est le pattern fondamental des agents.
- ☐ C La majorité des cas business nécessitent des architectures multi-agents complexes.
- ☐ D Le MCP (Model Context Protocol) transforme M×N intégrations en M+N.
- ☐ E Un agent autonome est recommandé dès qu'une tâche est répétitive.

QFJT Mécanisme des LLMs

- ☐ A Un LLM génère du texte en prédisant le prochain token.
- ☐ B Un token correspond exactement à un mot.
- ☐ C La Context Window est partagée entre l'entrée (prompt) et la sortie (réponse).
- ☐ D Un vocabulaire de tokens plus grand signifie plus de tokens par phrase, donc un coût plus élevé.
- ☐ E Les Thinking Tokens (raisonnement interne) sont facturés mais généralement supprimés de la réponse finale.

QWMN Deep Learning et Transformers

- ☐ A Le mécanisme d'attention (Transformer) est l'innovation de rupture qui a permis l'essor des LLMs.
- ☐ B Plus un réseau de neurones a de couches, plus il peut détecter des patterns complexes.
- ☐ C Le papier « Attention Is All You Need » qui introduit le Transformer a été publié en 2022.
- ☐ D BERT (2018) utilise le Supervised Learning classique pour son pré-entraînement.
- ☐ E ChatGPT a atteint 100 millions d'utilisateurs en 2 mois après son lancement.